1. Động Lực Cải Tiến Kiến Trúc (Motivation)

Trong mô hình DINOv1 gốc (`ViT-Small/16`), hai thành phần cốt lõi gặp phải hạn chế lớn:

Hạn chế 1: Mã hóa Vị trí Tuyệt đối (APE)

- **Méo hình học khi Multi-Crop**: DINO huấn luyện đồng thời ảnh 224×224 (196 patch) và 96×96 (36 patch). Bảng APE buộc phải nội suy bicubic $\Rightarrow$ gây sai lệch tương quan khoảng cách.
- **Thiếu tính bất biến tịnh tiến**: Không mô hình hóa trực tiếp khoảng cách tương đối giữa hai patch $(\Delta x, \Delta y)$.

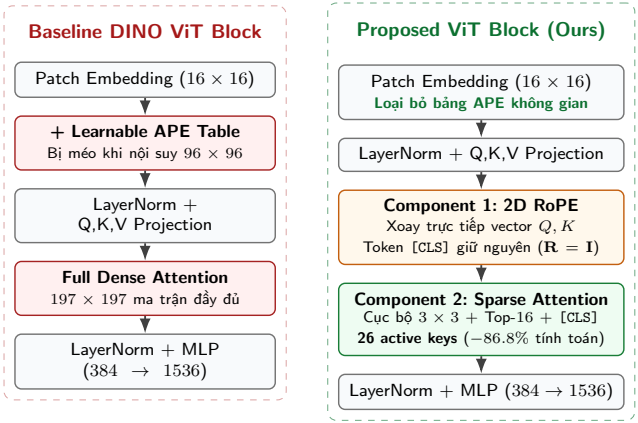
Hạn chế 2: Full Dense Attention $\mathcal{O}(N^2)$

- **Lãng phí tính toán nghiêm trọng**: Mọi token đều tương tác với toàn bộ 197 token, trong khi $> 85\%$ trọng số sau hội tụ xấp xỉ bằng 0.
- **Nhiễu nền (Background Clutter)**: Cơ chế Dense Attention khiến token `[CLS]` dễ bị phân tán vào nền trời, cỏ và bối cảnh xung quanh thay vì tập trung vào vật thể chính.

Mục tiêu Đề xuất

Thay thế APE bằng **Frequency-Adaptive 2D RoPE** & thay thế Dense Attention bằng **Spatial-Semantic**

2. Tổng Quan Kiến Trúc Đề Xuất (Architecture Overview)



Nguyên Lý Cốt Lõi

- **Giữ nguyên 100% tham số**: Backbone đạt đúng **21,665,664** tham số (bằng tuyệt đối với mô hình gốc).
- **Bảo toàn FLOPs lý thuyết**: **9.20 GFLOPs** tại độ phân giải 224×224.
- **Tính toán cục bộ & toàn cục**: 2D RoPE nhúng tọa độ liên tục; Sparse Attention gom đúng 26 khóa nổi bật ngữ nghĩa.

3. Component 1: Frequency-Adaptive 2D Rotary Position Embedding

Cơ Chế Xoay Vector 2D Không Gian

Phân chia chiều không gian head $d_h = 64$ thành 2 trục x, y:

$$d_x = d_y = 32, \quad M = 16 \text{ dải tần số } \omega_m$$

Vector Q và K được xoay qua ma trận trực giao $\mathbf{R}_\Theta$:

$$\tilde{\mathbf{q}}_i = \mathbf{R}_\Theta(p_{x,i}, p_{y,i})\mathbf{q}_i, \quad \tilde{\mathbf{k}}_j = \mathbf{R}_\Theta(p_{x,j}, p_{y,j})\mathbf{k}_j$$

Bất biến tịnh tiến tương đối qua tích vô hướng:

$$\langle \tilde{\mathbf{q}}_i, \tilde{\mathbf{k}}_j \rangle = \mathbf{q}_i^T \mathbf{R}_\Theta(p_{x,i} - p_{x,j},\, p_{y,i} - p_{y,j})\mathbf{k}_j$$

$\Rightarrow$ Tự động mã hóa khoảng cách hình học tương đối!

Lịch Phối Trộn Tọa Độ Thích Ứng Tần Số

Trộn tọa độ nguyên tuyệt đối và chuẩn hóa:

$$p_m = \alpha_m \cdot p_{\text{raw}} + (1-\alpha_m) \cdot p_{\text{norm}}, \quad \alpha_m = 1 - \frac{m}{M-1}$$

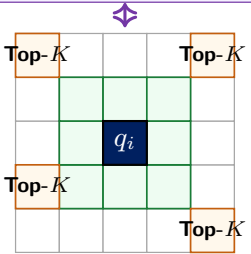
- **Tần số cao ($\alpha \to 1$)**: Tọa độ nguyên $\Rightarrow$ nắm bắt chi tiết texture và ranh giới sắc nét.
- **Tần số thấp ($\alpha \to 0$)**: Tọa độ chuẩn hóa $\Rightarrow$ bất biến tỷ lệ xuyên qua các crop 224^2 và 96^2.

Bảo Toàn Token [CLS]

[CLS] không có tọa độ không gian: gán

4. Component 2: Spatial-Semantic Sparse Softmax Attention

Cầu Nối Hai Chiều [CLS] (Index 0)
[CLS] nhìn mọi token &
mọi token đều nhìn [CLS]



3 Nhánh Hỗ Trợ Hoạt Động $\mathcal{S}_i$

Tập khóa hoạt động:
$\mathcal{S}_i = \mathcal{N}_{\text{local}}(i) \cup \mathcal{N}_{\text{semantic}}(i) \cup \{0\}$

1. **Cục bộ 3×3 ($\mathcal{N}_{\text{local}}$)**: 9 patch lân cận (Chebyshev $R = 1$).
2. **Ngữ nghĩa Top-K ($\mathcal{N}_{\text{semantic}}$)**: 16 patch có độ tương đồng tích vô hướng cao nhất.
3. **Cầu nối [CLS]**: Index 0 kết nối ngữ cảnh toàn cục.

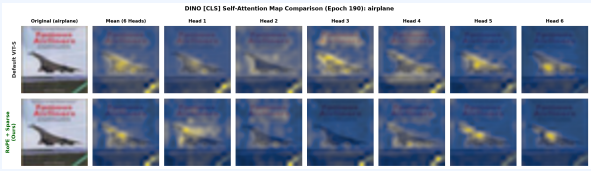
$\Rightarrow$ **Tổng khóa kích hoạt: 26 / 197 keys (Giảm 86.8% phép tính)**.

Chuẩn Hóa Softmax Chính Xác

$$\mathbf{A}_{ij} = \frac{\exp(\tilde{\mathbf{q}}_i^T \tilde{\mathbf{k}}_j / \sqrt{d_h})}{\sum_{l \in \mathcal{S}_i} \exp(\tilde{\mathbf{q}}_i^T \tilde{\mathbf{k}}_l / \sqrt{d_h})} \quad \forall j \in \mathcal{S}_i$$

5. Minh Chứng Trực Quan: Attention Maps & Hiệu Năng

So Sánh Attention Map 6 Heads (Epoch 190)



Phân Tích Định Tính

- **Baseline ViT**: Chú ý bị phân tán rộng vào nền trời phía sau.
- **RoPE + Sparse (Ours)**: Head 2 và Head 5 gom chặt sự chú ý vào đúng khung thân, cánh và đuôi máy bay, tách bạch hoàn toàn khỏi nền.

Cải Thiện Định Lượng (CIFAR-10)

- **k-NN Top-1** ($k = 10$): $74.41\% \rightarrow \mathbf{75.97}\%$ (**+1.56% gain**).
- **Linear Probing Top-1**: $81.46\% \rightarrow \mathbf{83.98}\%$ (**+2.52% gain**).
- **Tốc độ hội tụ phân loại**: Epoch 10: $73.76\% \rightarrow \mathbf{79.86}\%$ (**+6.10%**).

Kết Luận Phần 2

2D RoPE + Sparse Attention giải quyết trọn vẹn bài toán bảo toàn hình học và khử nhiễu nền mà **không tăng chi phí tham số**.